

Projet - Reconnaissance des Formes

M1 Master Informatique – année 2024 / 2025

Problématique

Nous considérons dans ce projet une base d'images, appelée SharvitB2, qui a servi de fondement à de nombreux travaux en reconnaissance des formes (robustesse à des occultations, comparaison d'approches polygonales, fusion de méthodes...). Cette petite base est composée de formes binaires représentant des classes d'objets à reconnaître. Elle comprend 18 classes (oiseau, clef, tortue, fourche...) de 12 échantillons pouvant avoir des déformations et des orientations variables (cf. Figure1).

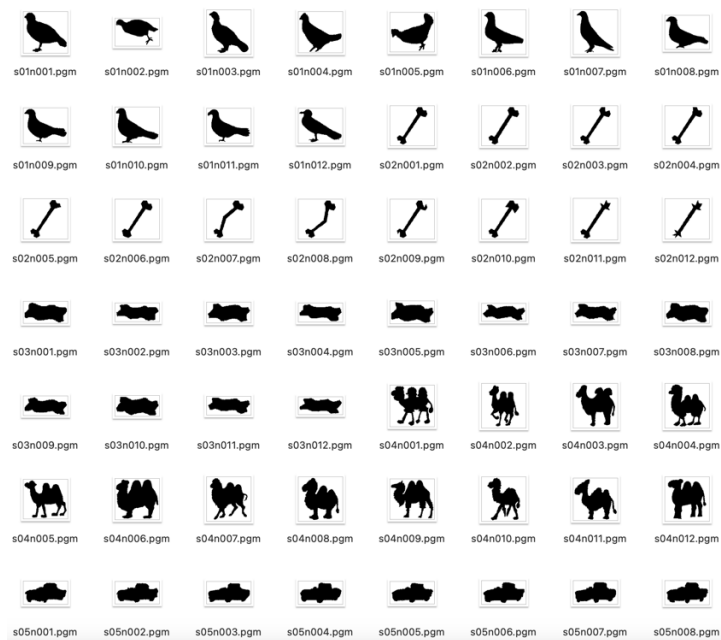


Figure 1. Échantillons de la base de formes SharvitB2 (18x12)

Chaque forme est une image binaire stockée sous la forme SxxNyyy.pgm. Sxx correspond à la classe xx et Nyyy correspond à l'échantillon yyy de la classe. Ces fichiers au format pgm ne servent ici qu'à la visualisation.

Des représentations de ces formes (vecteurs caractéristiques) ont été obtenues en appliquant cinq méthodes classiques servant de fondement à de nombreux travaux en recherche en reconnaissance des formes :

- ART : représentation définie à partir d'une transformée radiale de l'image [1],

- ZRK : correspond aux moments de Zernike (déterminés à partir des polynômes complexes de Zernike calculés sur un disque unité) [2],
- E34 (définie à partir des moments d'ordre 2) : correspond au *degré d'ellipticité* calculé sur des coupes de niveau de la forme (à partir d'une transformée de distance) [3],
- GFD (définie à partir d'une transformée discrète polaire) : correspond à un *descripteur de Fourier générique* (en fonction de fréquences radiales et angulaires) [4],
- YNG : signature structurelle définie à partir des points du squelette de la forme [5].

Pour chaque image SxxNyyy.pgm de BDshape, des fichiers SxxNyyy.MET ont été générés pour faciliter les traitements. L'extension du fichier MET définit le type de *méthode* qui a été calculée sur l'image associée. C'est-à-dire dans ce projet : SxxNyyy.E34 (pour l'ellipticité) et SxxNyyy.GFD (pour les descripteurs de Fourier Générique),....

L'objectif du projet est *d'évaluer*, sur une petite base complexe, le comportement de ces méthodes classiques de reconnaissance des formes (notées \mathbf{M}^{ART} , \mathbf{M}^{GFD} ...) en associant leur représentation à un *classifieur*.

Remarque : les fichiers correspondant à ces représentations sont accessibles à l'adresse : <http://helios2.mi.parisdescartes.fr/~lwendlin/RF2024/PROJET/> ainsi qu'une archive PGM qui contient toutes les formes (uniquement pour visualisation)

-
- [1] Kim, W.-Y., Kim, Y.-S.: A new region-based shape descriptor. In: TR 15-01, Pisa, Italy (1999)
 - [2] Khotanzad, A., Hong, Y.H.: Invariant Image Recognition by Zernike. IEEE TPAMI 12(5), 489–497 (1990)
 - [3] R. Teague, Image analysis via the general theory of moments, J. Opt. Soc. Amer. 70(8) 920–930, (1979).
 - [1] Yang, S.: Symbol Recognition via Statistical Integration of Pixel-Level Constraint Histograms: A New Descriptor. IEEE TPAMI 27(2), 278–281 (2005)
 - [4] Zhang, D., Lu, G.: Shape-based image retrieval using generic fourier descriptor. Signal Processing: Image Communication 17, 825–848 (2002)

Travail à faire

Le travail est à réaliser **en binôme** et comporte 4 étapes :

1. Lecture des données
2. Implémentation de 3 approches de classification (*voir annexe*)
 - a. Approche des k-plus-proches voisins – supervisée (distance, choix de k...)
 - b. Approche des nuées dynamiques (ou *k-means*) – non supervisée
 - c. Au choix : SVM, MLP ou vote majoritaire (*)
3. Protocole de test (lorsque c'est possible)
 - a. Choix du mode d'évaluation (découpage des données) pour les approches
 - b. Critères d'évaluation (matrice, F-mesure...)
 - c. Courbe précision/rappel (et AUC) avec K=12
4. Étude expérimentale
 - a. Analyse du comportement des méthodes en fonction des critères d'évaluations,
 - b. Discussion sur les résultats (améliorations possibles, impact des approches de classification...)
5. Conclusion et perspectives

(*) Vous pouvez utiliser des codes déjà existants

Remarque :

- a) L'objectif de ce mini-projet est d'intégrer des notions développées en cours. Une interface n'est pas requise et l'exécution du code peut se faire en ligne de commande.
- b) Les études comparatives peuvent être distinctes suivant les approches de classification.

Documents à rendre

1. Un dossier d'analyse (au format pdf) comportant les réponses aux questions précédentes et tout commentaire permettant de justifier votre démarche (entre 10 et 15 pages maximum).
2. Une archive du code commenté (C/java) pour toutes les approches.
3. Une présentation contenant une dizaine de slides maximum décrivant votre démarche et les problèmes rencontrés.

Dates butoirs

Le projet comporte deux dates butoirs :

10/12/2024 : remise du dossier d'analyse et du code (mail à Laurent.Wendling@u-paris.fr)
17/12/2024 : présentation (Zoom) de 10 minutes par binôme (envoi du document pdf deux jours au préalable)

Annexe

The k-Nearest Neighbor Classifier

- Given the training data $D = \{x_1, \dots, x_n\}$ as a set of n labeled examples, the nearest neighbor classifier assigns a test point x the label associated with its **closest neighbor** in D .
- The k -nearest neighbor classifier classifies x by assigning it the label most frequently represented among the k nearest samples.




Figure 2: Classifier for $k = 5$.

- Closeness is defined using a **distance function**.

Distance functions

- A general class of metrics for d -dimensional patterns is the **Minkowski metric**.

$$L_p(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^p \right)^{1/p}$$

also referred to as the **L_p norm**.

- The **Euclidean distance** is the L_2 norm

$$L_2(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^2 \right)^{1/2}$$

- The **Manhattan or city block distance** is the L_1 norm

$$L_1(x, y) = \sum_{i=1}^d |x_i - y_i|$$

Squared-error Partitioning (clustering)

- Suppose that the given set of n patterns has somehow been partitioned into k clusters D_1, \dots, D_k .
- Let n_i be the number of samples in D_i and let m_i be the mean of those samples

$$m_i = \frac{1}{n_i} \sum_{x \in D_i} x$$

- Then, the sum-of-squared errors is defined by:

$$m_i = \sum_{i=1}^k \sum_{x \in D_i} \|x - m_i\|^2$$

- For a given cluster D_i , the mean vector m_i (centroid) is the best representative of the samples in D_i .
- A **general algorithm** for iterative squared-error partitioning:
 1. Select an **initial partition** with k clusters (*repeat steps 2 through 5 until the cluster membership stabilizes*).
 2. Generate a **new partition** by assigning each pattern to its **closest** cluster center.
 3. Compute **new cluster centers** as the centroids of the clusters.
 4. Repeat steps 2 and 3 until an **optimum value of the criterion function** is found (e.g., when a local minimum is found or a predefined number of iterations are completed).
 5. Adjust the number of clusters by **merging** and **splitting** existing clusters or by removing small or outlier clusters.

This algorithm, without step 5, is also known as the **k-means algorithm**.